

Guía: grabar los videos para entrenar el modelo

Captura y etiquetado masivo con SAM2 — AR Shoe Try-On

Proyecto: ar-shoes (3DCommerceCL) Versión: 1.0 — julio 2026 Fuente: training/GUIA_VIDEOS.md

Por qué videos y no fotos

con SAM2 clickeás el pie/zapato/pierna **una sola vez** en el primer frame y las máscaras se propagan solas a todo el clip. Un video de 30 s rinde cientos de frames etiquetados por ~1 minuto de trabajo (contra ~2 min por foto). Es la misma estrategia de datos que usan Wanna y Kivisense.

1. El encuadre: esto es lo más importante

Grabá **exactamente lo que va a ver la app**: una persona parada, teléfono en mano, mirando hacia sus propios pies. Ese encuadre "POV" es el que hizo fracasar a MediaPipe y la razón por la que entrenamos modelo propio — así que el dataset tiene que estar dominado por él.

Regla	Por qué
Pies CENTRADOS en el cuadro	El modelo (y la app) solo ven el cuadrado central de la imagen. Lo que quede arriba o abajo de ese cuadrado se descarta. Si los pies quedan al fondo del cuadro, se pierden.
Incluí parte de la pierna / pantalón	La frontera pierna↔zapato es lo que el modelo debe aprender para la oclusión.
Teléfono en vertical, como se usa	Coincide con el uso real.
Distancia: 60 cm – 1.5 m	Como cuando mirás tus pies parado. No macro pegado al zapato.

Repartí los clips entre estos ángulos: ~40 % mirando casi a plomo hacia abajo (cenital), ~30 % en diagonal (el típico "selfie de pies"), ~20 % de frente a la altura de la rodilla, ~10 % lateral.

2. Cuántos clips y de qué duración

- **Duración ideal: 20–40 s** por clip. Clips de 10 s también sirven (rinden menos frames).
- **Meta: 20–30 clips** en total, con **≥ 5 personas** distintas.
- **Arrancá con 3–5 clips** para validar el flujo completo antes de producir en masa.
- Regla clave: **la variación va ENTRE clips, no dentro de un clip**. Cada clip = una persona, un calzado, un piso, una luz. Cambiá esas cosas al pasar al siguiente.

3. Reglas de oro para que SAM2 no falle

Estas cinco condicionan que la propagación automática funcione. No son opcionales:

1. **Movimientos LENTOS.** El motion blur es el enemigo n.º 1: si el frame sale movido, SAM2 pierde el objeto y todos los frames siguientes salen mal. Movete a la mitad de la velocidad que te parece natural.
2. **El primer frame es sagrado.** Es donde vas a hacer los clics. Tiene que mostrar **pie, zapato y pierna bien visibles, nítidos y sin nada que los tape**. Si el clip empieza con el pie movido o cortado, no sirve.
3. **El pie nunca sale del cuadro.** Que salga y vuelva a entrar rompe el seguimiento.
4. **Luz constante dentro del clip.** No pases de sol a sombra en el mismo clip; grabá dos clips.
5. **Bloqueá exposición y foco** si tu teléfono lo permite (mantené el dedo apretado sobre la pantalla hasta que aparezca "AE/AF Lock"). Evita que la cámara "respire" cambiando brillo.

4. Qué variar entre clips (la diversidad es lo que da precisión)

Variable	Qué cubrir
Personas	Mínimo 5 distintas: distinto tono de piel, tamaño y forma de pie
Calzado	Zapatillas, zapatos, botas, sandalias, medias/calcetines y pie descalzo
Pierna	Mitad con pantalón cubriendo el tobillo (largo y corto), mitad con pierna descubierta
Piso	≥ 6 tipos: madera, cerámico, alfombra, cemento, exterior (pasto/vereda), piso oscuro
Luz	Natural, artificial cálida, mixta, contraluz suave, sombra dura del propio pie

5. Qué hacer dentro de cada clip (20–40 s dan para todo esto)

Movimientos lentos, encadenados:

1. Quedate quieto 2 s al principio (ese es el frame de los clics).
2. Caminá **en el lugar**, despacio.
3. **Girá el pie**: punta hacia adentro, hacia afuera.
4. **Levantá el talón** (como al dar un paso) y bajalo.
5. Un paso adelante y uno atrás.
6. Movés vos la cámara: acercate y alejate un poco, y describí un arco lento alrededor del pie.

Ese repertorio le enseña al modelo el pie en todas las poses que necesita.

6. Configuración del teléfono

- **1080p a 30 fps** (no hace falta 4K; pesa el triple y no aporta).
 - **Vertical**.
 - **No uses el lente ultra gran angular** (el 0.5x): deforma la perspectiva y no coincide con el lente que usa la app.
 - Limpiá el vidrio de la cámara (suena tonto; una huella arruina el clip).
 - Sin filtros, sin cámara lenta, sin estabilización "cinematográfica" agresiva.
-

7. Dónde dejar los archivos

```
c:\Users\Iga\Documents\ar-shoes\training\data_videos\
```

Nombres **sin espacios ni acentos**: `clip01.mp4`, `clip02.mp4`, ... El nombre del archivo se usa como identificador y garantiza que todos los frames de un mismo video vayan juntos a entrenamiento o a validación (nunca separados: si se separaran, la métrica de precisión saldría falseada).

Los videos **no se suben al repositorio** (están en `.gitignore`): quedan solo en tu máquina.

8. Cómo se procesan

```
cd training
py -3 2b_sam2_video.py --video data_videos/clip01.mp4 --extract_stride 3 --max_side 640
```

Se abre el primer frame y hacés los clics:

Tecla / acción	Qué marca
2 + clic	El pie (piel visible: empeine, tobillo)
3 + clic	El zapato
1 + clic	La pierna / pantalón
clic derecho	Punto negativo: corrige si la máscara se desborda
R	Resetear los clics
ENTER	Propagar a todo el clip y exportar

Después, para revisar y descartar los frames donde la propagación se perdió:

```
py -3 2b_sam2_video.py --review --out data
```

(Cualquier tecla = siguiente frame, **D** = borrar ese frame, **Q** = salir.)

 **Tiempo:** en CPU es lento (~10 s por frame procesado). Un clip de 10 s con `--extract_stride 3` son ~100 frames ≈ 15–20 min. Para procesar muchos clips conviene GPU (el mismo script en Google Colab con `--device cuda` tarda un par de minutos por clip).

9. Checklist antes de grabar

- ☐ Teléfono en vertical, 1080p/30fps, lente normal (no 0.5x)
- ☐ Exposición y foco bloqueados
- ☐ Los pies quedan **en el centro** del cuadro, con parte de la pierna visible
- ☐ El clip **empieza** con 2 s quietos y el pie nítido y despejado
- ☐ Todo el clip es una sola combinación de persona/calzado/piso/luz
- ☐ Movimientos lentos, sin que el pie salga del cuadro
- ☐ Nombre `clipNN.mp4` en `training/data_videos/`

Errores comunes

Error	Consecuencia
Movimientos rápidos / motion blur	SAM2 pierde el objeto: el clip entero se descarta
Pies al borde inferior del cuadro	El recorte cuadrado central se los come
Primer frame movido o con el pie tapado	No se puede clicar bien: hay que descartar el clip
Cambiar de calzado o piso dentro del mismo clip	Los clics del frame 1 dejan de corresponder
Grabar con ultra gran angular (0.5x)	La deformación no coincide con la cámara de la app
Sol a sombra dentro del clip	La máscara se degrada al cambiar el brillo

Documento generado desde [training/GUIA_VIDEOS.md](#) — ante cualquier diferencia, el .md del repo es la fuente de verdad. Proyecto ar-shoes · ROADMAP.md tarea T3.7.